

HEC MONTRÉAL

Rapport

Travail présenté à

Martin Cousineau

Dans le cadre du cours

Analytique de la chaîne logistique

OPER60500.E2026

Par

Émile Jeannotte 11315230

Hannaé Ribardière 11303359

Lise Devillers 11284950

Le 22 juin 2026

Table des matières

1. Introduction.....	2
2. Méthode	3
2.1 Étape 1 : préparation des données.....	3
2.2 Étape 2 : modèles de prévision et stratégie de validation	4
2.3 Étape 3 : prévision finale et politique de stock	6
3. Analyse des résultats.....	7
3.1 Meilleur modèle	7
3.2 Analyse prédictive : les prévisions du modèle	8
3.3 Analyse prescriptive : stocks cibles	9
4. Conclusion	12
4.1 Limites : à revoir, juste des idées	12
4.2 Voies d'amélioration du projet	12
5. Contribution des membres de l'équipe	13
6. Déclaration sur l'utilisation de l'IA générative	13
7. Bibliographie.....	14

1. Introduction

Dans le cadre de ce projet portant sur l'analyse prédictive, notre équipe s'est posée sur un problème de gestion des stocks d'une compagnie réelle qui manufacture du matériel électrique. Cette compagnie produit des items selon les spécifications des clients, qui ne sont pas conservés en inventaire lorsqu'il n'y a pas une vente, mais aussi des produits de type « make-to-stock » qui sont gardés en inventaire afin de répondre à la demande périodique de leurs clients, qui peuvent autant être les utilisateurs finaux que des distributeurs. Notre projet va donc spécifiquement se porter sur la gamme de produits qui est fabriquée dans le but d'être conservée en inventaire.

Nous avons donc approché l'équipe de production de la compagnie, afin de recueillir les données de leur vente mensuelles et leur demander leur approche quant à la gestion des stocks du matériel électrique. Ils nous transmittent les données des ventes de 2 produits typiques de leur segment de production « make-to-stock » après les perturbations reliées à la pandémie de COVID-19, soit du 1^{er} janvier 2022, au 1^{er} juin 2026, sous la forme de fichiers Excel (.xlsx). La compagnie souhaitant rester anonyme, ils nous ont demandé de masquer le SKU des 2 produits, que nous avons renommés ITEM001 et ITEM002, cependant les données sont réelles. De plus, ils nous ont annoncé que leur politique de gestion des stocks est de viser un niveau de stock équivalent à la demande pour 3 mois. Cette demande mensuelle repose sur une moyenne mobile sur 12 mois. Ils désirent donc, présentement, maintenir un niveau de stock équivalent à 3 fois la moyenne des ventes mensuelles des 12 derniers mois. Cependant, ils nous ont exprimé que ce niveau de stock souhaité n'est pas nécessairement appliqué systématiquement et les ventes vont beaucoup varier à travers les périodes, compliquant la prévision des niveaux de stocks appropriés. Les niveaux de stocks réels sont alors rarement équivalents à 3 mois de demande, ce que reflète les données.

Les données de ventes historiques qui nous ont été transmises affichent, plus précisément, le niveau de stock au début de la période, soit le 1 janvier 2022. Ensuite, chaque ligne indique, soit une entrée de stock, indiquée par le préfixe « RCP », soit une sortie de stock, sous le préfixe « SHIP ». La date d'entrée en inventaire correspond à la date de fin de la production, puisque l'entrepôt est dans le même bâtiment que le plancher de production, et la date de sortie d'inventaire correspond à la date à laquelle le produit vendu a été expédié au client. Les retours de stocks, dont la raison n'est pas spécifiée, sont aussi affichés dans le rapport, sous le préfixe « CN ». Chacune de ces opérations affiche la quantité de produits impliquées, la date de l'opération et le niveau de stock à la suite de l'opération, en plus du coût de production pour la quantité en inventaire à la date de l'opération. Les données sont exactes et sont extraites directement du ERP de la compagnie, qui enregistre toutes entrées en inventaire et sorties d'inventaires.

Comme la compagnie nous l'a mentionné, une problématique est présente dans la prévision de la demande, ce qui complique la gestion des niveaux d'inventaires du segment « make-to-stock ». Le but de notre projet est alors de développer un outil de prévision de la demande pour les deux produits ITEM001 et ITEM002, puis de comparer les prévisions obtenues à l'aide de cet outil à la méthode actuelle de la compagnie, soit la moyenne mobile sur 12 mois, ce qui nous permettra de déterminer si un nouveau modèle de prévision, dont l'erreur est moins élevée, serait plus approprié pour la gestion des

stocks de la compagnie. Il nous sera ensuite possible d'effectuer une prévision de la demande pour la fin de l'année 2026, soit de juin à décembre, et de proposer un niveau de stock qui se révélera plus approprié pour ces deux produits et qui pourrait être généralisée aux autres items de la catégorie "make-to-stock".

2. Méthode

Toutes les librairies nécessaires ont été installées en début de notebook via la commande *pip install* et *import*, notamment *pandas* et *numpy* pour les données en tableaux, *matplotlib* et *seaborn* pour les graphiques, et *darts* pour précisément créer le cœur de l'outil de prévision avec l'usage de différents modèles.

2.1 Étape 1 : préparation des données

Dans le but de simplifier le code, nous avons transformé les deux rapports (fichiers Excel) en fichiers CSV distincts, puisque l'export depuis l'ERP crée un en-tête de description inutile pour le développement de l'outil en tant que tel. Chaque fichier contient les transactions de janvier 2022 à mai 2026, soit 53 mois. Les fichiers présentent une structure classique de fichier CSV : colonnes séparées par des points-virgules, quantités dans un format numérique modifié par la suite dans le notebook Python, et dont chaque ligne correspond à un unique mouvement de stock plutôt qu'une période donnée. Leur importation dans le notebook s'est faite par l'usage de liens *github* avec *pd.read_csv()*. Le dictionnaire nommé *COLS* a permis de mettre un indice à chacune des colonnes utiles dans les fichiers CSV (date, type, quantités entrantes et sortantes).

Comme mentionné dans la première partie, les fichiers présentent différents types de mouvement qu'il faut distinguer. Seules les lignes *Shipment* sont retenues comme ventes. Les lignes *Credit Note* correspondent aux retours de marchandises, dont la quantité est soustraite aux ventes pour obtenir les ventes nettes. Les lignes *Receipt* et *Assm. Master* sont ignorées car elles représentent des mouvements d'approvisionnement et non des ventes. La fonction *parser_produit* permet de traiter les données brutes du fichier CSV selon cette logique.

Dans notre outil (dans la partie « Fonction de traitement CSV), les transactions affichées par jour sont rassemblées par mois. Un index mensuel est ensuite sorti de janvier 2022 à mai 2026 (*ventes* avec un *groupby()*) et les mois sans transaction sont comblés par la valeur zéro (*fillna(0)*). Cette méthode nous paraît cohérente pour la nature *make-to-stock* des items analysés. En effet, une absence de sortie de stock sur un mois donné ne veut pas nécessairement dire une absence de demande, seulement un possible décalage de commande. L'ITEM001 présente 9 mois à zéro mouvement sur 53 mois tandis que l'ITEM002 en présente 6. Cela caractérise une demande que l'on peut considérer comme intermittente légère.

À l'aide de ces données, un premier graphique (*Fig. 1*) représentant les ventes mensuelles nettes de chaque item sous forme de nuage de points. Ce graphe permet d'observer la présence d'une tendance de la demande, ainsi que de valider la cohérence des données traitées ensuite avec les modèles de prévisions dans les étapes suivantes.

Ventes mensuelles nettes (2022 - mai 2026) - zone violette = test 2026




Figure 1 : Ventes mensuelles nettes

Un second graphique présentant les volumes de ventes annuels (Fig. 2) permet de comparer l'évolution entre les années de manière plus directe visuellement, avec l'année 2026 partielle (janvier à mai 2026).




Figure 2 : Volume annuel des ventes de 2022 à 2026 (janvier à mai)

2.2 Étape 2 : modèles de prévision et stratégie de validation

Notre outil analytique offre l'approche suivante : les modèles sont entraînés sur les 48 premiers mois (de janvier 2022 à décembre 2025) et testés sur les 5 derniers mois réels (de janvier à mai 2026) qui n'ont jamais été considérés pendant l'entraînement. Cette séparation des données assure une évaluation des modèles en conditions réelles. La méthode actuelle de la compagnie, soit la moyenne mobile 12 mois (MM12), est utilisée comme référence.

8 modèles sont comparés :

- *MM12* : référence actuelle qui sert de comparaison.
- *NaiveSeasonal* : répète la valeur du même mois de l'année précédente.
- *ExponentialSmoothing* (lissage exponentiel, méthode Holt-Winter) : utilise le niveau, tendance et saisonnalité par pondération décroissante des observations passées.

- *Theta* : décompose les données en deux composantes et extrapole chacune séparément. Le mode additif est utilisé dans notre outil puisque les données concernées contiennent des mois à zéro mouvement, qui sont incompatibles avec le mode multiplicatif (division par zéro).
- *AutoARIMA* : sélectionne automatiquement les paramètres p , d , q du modèle ARIMA avec une minimisation de l'AIC.
- *Prophet* : décompose la série de mouvements en tendance, saisonnalité annuelle et résidus.
- *Croston* : modélise séparément l'intervalle entre les demandes non nulles et la taille des demandes.
- *NaiveEnsembleModel* : moyenne des prévisions de *NaiveSeasonal*, *Theta*, *Croston* obtenues en amont.

Ces huit modèles sont comparés à l'aide de graphiques mettant en valeur les prévisions sorties dans la période de test de début 2026 pour chacun des modèles et aussi dans un graphique les rassemblant pour chacun des items (*Fig. 3 et 4*).




Figure 3 : Comparaison des modèles pour l'ITEM001




Figure 4 : comparaison des modèles pour l'ITEM002

Deux mesures d'erreur sont retenues :

- *wMAPE* (*weighted Mean Absolute Percentage Error*) : calcule le ratio de l'erreur absolue totale sur la demande réelle. Nous avons privilégié cette mesure qui est plus robuste aux mois à zéro mouvement que le *MAPE* classique.
- *RMSSE* (*Root Mean Squared Scaled Error*) : normalise l'erreur quadratique par celle d'un modèle naïf saisonnier avec un K fixé à 1. Inférieur à 1 signifie que le modèle bat la prévision naïve de référence.

Pour chaque produit, nous avons créé une boucle qui sort, en plus des prévisions en figures 3 et 4, un tableau récapitulatif de la performance de chacun des modèles par rapport aux mesures d'erreur.

Cette boucle permet également, avec les données du tableau, d'obtenir un graphique de barres groupées présentant les deux mesures d'erreurs pour chacun des modèles sur les deux items avec une comparaison avec la moyenne mobile sur 12 mois (Fig. 5).




Figure 5 : récapitulatif de la performance des modèles pour les 2 items

2.3 Étape 3 : prévision finale et politique de stock

Le meilleur modèle identifié à l'étape 2 est entraîné à nouveau sur l'ensemble des données disponibles (janvier 2022 à mai 2026, soit 53 mois) afin de maximiser la quantité d'information. Il génère ensuite les prévisions pour les 7 mois restants de 2026.

La politique de stock recommandée repose sur la formule classique de stock de sécurité pour la politique *make-to-stock* de la compagnie :

$$\text{Stock de sécurité} = z * RMSE * \sqrt{\text{délai de réapprovisionnement}}$$

$$\text{Stock cible} = \text{demande prévue} * \text{délai} + \sqrt{\text{délai de sécurité}}$$

Le *RMSE* utilisé est celui trouvé sur la période de test (janvier à mai 2026). Il quantifie l'incertitude réelle du modèle choisi plutôt que la variation de la demande historique, ce que nous trouvons plus rigoureux. Le *z-score* est de 1.645, ce qui correspond à un niveau de service de 95% avec un délai de réapprovisionnement de 1 mois, pour refléter la réalité de la compagnie.

Enfin, une simulation de la politique de stock (*s*, *S*) est utilisée sur les données de janvier à mai 2026 pour observer le taux de remplissage obtenu précédemment. À chaque mois, si le stock disponible additionné aux commandes en transit tombe sous le stock cible, une commande est passée pour atteindre le niveau cible. Ainsi, le taux de remplissage mesure la proportion de demande satisfaite.

Cette prévision finale est présentée dans un graphe de nuages de point tandis que les stocks cibles le sont dans un graphe à barres, cela pour chacun des items.

3. Analyse des résultats

3.1 Meilleur modèle

Le modèle de prévision le plus performant pour les codes ITEM001 et ITEM002 a été déterminé en comparant les résultats des 8 modèles de prévision de la demande analysées. Nous avons ciblé la racine de l'erreur quadratique moyenne mise à l'échelle (RMSSE) comme mesure d'erreur nous permettant de comparer les modèles, donc celui avec le plus bas RMSSE a été classé comme le plus performant pour ce SKU et a été retenu pour faire l'analyse prédictive des ventes pour la fin de l'année 2026. La figure 6 affiche les mesures d'erreur obtenues avec chaque modèle.

Classement complet - ITEM001				
Model	RMSSE	wMAPE	RMSE	
Prophet	0.583	25.2%	38.3	
ExponentialSmoothing	0.620	28.2%	40.7	
AutoARIMA	0.766	36.4%	50.3	
MM12	0.812	38.2%	53.3	
Theta	0.840	39.3%	55.1	
Ensemble(show_w	0.899	44.4%	59.0	
Croston	1.026	46.7%	67.3	
NaiveSeasonal	1.172	47.2%	76.9	
Classement complet - ITEM002				
Model	RMSSE	wMAPE	RMSE	
MM12	1.094	38.3%	60.7	
Prophet	1.212	38.1%	67.2	
Theta	1.281	48.7%	71.1	
ExponentialSmoothing	1.318	45.3%	73.1	
AutoARIMA	1.333	50.1%	74.0	
Croston	1.348	50.7%	74.8	
Ensemble(show_w	1.403	45.9%	77.9	
NaiveSeasonal	2.105	78.0%	116.8	

Figure 6 : Mesures d'erreur de chacun des modèles pour les 2 items

Pour le produit ITEM001, nous remarquons que 3 modèles ont un RMSSE moins élevé que le modèle présentement utilisé, la moyenne mobile sur 12 mois, donc sont plus performants, Prophet, le lissage exponentiel et ARIMA. Cependant, pour faire les prévisions de la fin de l'année 2026, seul le modèle

avec le plus bas RMSSE a été retenu. Le modèle hybride Prophet, avec un RMSSE de 0.583 représente une amélioration de 28.2% par rapport au 0.812 obtenu avec la méthode actuelle.

Pour le produit ITEM002, parmi les 8 modèles de prévision qui ont été utilisés, aucun des modèles n'a été plus performant que le modèle déjà utilisé par la compagnie, soit la moyenne mobile sur 12 mois, en termes de RMSSE. En effet, la moyenne mobile a un RMSSE de 1.094 et le modèle qui a fini second, soit Prophet, n'a obtenu qu'un RMSSE de 1.212. Cependant, lorsqu'on observe le wMAPE, le modèle Prophet s'est montré plus performant avec un résultat de 38.1%, contre 38.3% avec la moyenne mobile. Néanmoins, comme mentionnée auparavant, la mesure d'erreur principale pour évaluer le meilleur modèle est le RMSSE, donc la moyenne mobile sur 12 mois est le modèle le plus performant pour l'ITEM002, mais les deux modèles ont été retenus pour faire les prévisions des ventes des sept derniers mois de 2026. Cela fait en sorte que nous avons prévu 2 scénarios, un réalisé avec la moyenne mobile et un réalisé avec Prophet.

3.2 Analyse prédictive : les prévisions du modèle

Le modèle de prévision utilisé pour le produit ITEM001 est le modèle hybride Prophet, qui a obtenu un RMSE de 38.3 sur le groupe test de début de 2026. Les prévisions obtenues pour les sept derniers mois de 2026 sont affichées dans la figure 7.




Figure 7 : Prévisions obtenues pour l'ITEM001 avec Prophet (juin à décembre 2026)

Puisque le matériel électrique est vendu en unités, les prévisions de ventes ont été arrondies à l'entier supérieur. On peut donc observer des ventes prévues de 130 unités, 85 unités, 101 unités, 123 unités, 170 unités, 98 unités et 92 unités pour les périodes de juin, juillet, août, septembre, octobre, novembre et décembre 2026, respectivement.

Pour le produit ITEM002, les deux modèles qui ont été retenus pour faire la prévision des ventes sont la moyenne mobile sur 12 mois, soit le même modèle que la compagnie utilise présentement et le modèle Prophet. La moyenne mobile a obtenu un RMSE de 60.7 sur le groupe test du début 2026 et les ventes prévues, sous ce premier scénario, pour les sept dernières périodes de 2026 sont de 93 unités vendues pour chaque période, ce qui peut être observée dans la figure 8.




Figure 8 : Prévisions obtenues pour l'ITEM002 avec MM12 (juin à décembre 2026)

Avec le modèle Prophet, qui a été utilisé pour produire le second scénario, un RMSE de 67.2 a été obtenu sur le groupe test du début de 2026, ce qui légèrement supérieur qu'avec la moyenne mobile. Les ventes prévues dans ce second scénario sont de 110 unités, 102 unités, 97 unités, 96 unités, 137 unités, 142 unités et 120 unités pour les périodes de juin, juillet, août, septembre, octobre, novembre et décembre 2026, respectivement, ce qui peut être observé dans la figure 9.




Figure 9 : Prévisions obtenues pour l'ITEM002 avec Prophet (juin à décembre 2026)

3.3 Analyse prescriptive : stocks cibles

Nous avons cherché à évaluer l'influence de nos prévisions les plus précises (Prophet) sur notre politique de gestion des stocks pour la période allant de juin à décembre 2026.

Tout d'abord, le modèle Prophet et l'intégration de son RMSE garantissent le maintien au-dessus du niveau de service souhaité de 95 %, en particulier un taux de remplissage se rapprochant de 100 %. Par conséquent, pour l'article ITEM001, on constate un niveau de sécurité de 63 unités et un inventaire moyen de 52,6 unités. Cela permet de satisfaire environ 99,5 % de la demande.




Figure 10 : Stocks cibles de l'ITEM001 pour juin à décembre 2026 avec Prophet

En ce qui concerne l'ITEM002, le niveau de sécurité est de 110,6 et l'inventaire moyen est de 106,9. Cela devrait couvrir environ 100 % de la demande.




Figure 11 : Stocks cibles de l'ITEM002 pour juin à décembre 2026 avec Prophet

Il est pertinent de se poser la question de savoir si les performances actuelles sont supérieures à l'ancienne politique. En adoptant une politique visant un stock cible égal à trois mois de demande mensuelle (en supposant pour notre période de test, que la demande est égale aux ventes réelles et que l'horizon est égale à 7 mois), on obtiendra :

- Demande moyenne d'ITEM 001 = $(129,2 + 84,9 + 100,4 + 122,5 + 169,8 + 97,3 + 91,9)/7 = 113,7143$

- Demande moyenne d'ITEM 002 = $(109,7 + 102,0 + 96,9 + 95,3 + 136,1 + 141,8 + 119,4)/7 = 114,4571$

Ainsi, pour l'ITEM001, le stock cible moyen serait de $3 \times 113,7143 = 341,1429$ au lieu de 176,7 avec la politique intégrant le RMSE. On diminue donc la quantité moyenne de l'inventaire cible de 163,2 unités. Pour l'article ITEM002, l'inventaire cible moyen serait de $3 \times 114,4571 = 343,3713$ au lieu de 225,1, ce qui représente une réduction de 118,3 unités. Cela divise presque par deux les niveaux de stocks cibles moyens, sans courir le risque d'interruption. En effet, comme le montrent les graphiques des stocks, les

niveaux des stocks cibles sont constamment atteints et couvrent l'ensemble de la demande prévue, tout en laissant une marge de manœuvre pour faire face à une demande imprévue accrue. Ces niveaux paraissent plus réalistes et pratiques par rapport à la politique actuelle, qui n'est pas rigoureusement appliquée en raison de son caractère difficile à respecter.

Toutefois, pourrait-on encore l'optimiser ? En examinant de plus près, nous constatons que nos taux d'occupation sont tous deux presque à 100 %, ce qui nous amène à nous demander si nous pourrions expérimenter différents facteurs z pour atteindre un niveau de service de 95 % et ainsi réduire notre inventaire moyen (ce qui entraînerait des économies de stockage). Nous pourrions viser un niveau de service théorique de 90 % et examiner si cela nous rapproche réellement d'un niveau de 95 %. On pourrait se questionner sur l'origine de ce surstockage. Une explication possible pourrait être notre formule du stock de sécurité, qui part du principe d'une distribution normale des erreurs. Il est possible que le comportement réel de la demande et les capacités de Prophet ne répondent pas entièrement aux attentes.

De plus, le RMSE reste constant pour les deux éléments, ce qui fournit une marge de sécurité constante, mais les incertitudes de prévision ont tendance à augmenter à mesure que l'horizon de prévision s'éloigne. Par conséquent, un moyen d'optimiser le modèle pourrait être d'y inclure une incertitude dynamique de Prophet, ce qui permettrait d'avoir un inventaire de sécurité plus flexible et d'ajuster ainsi plus efficacement les niveaux des

3.4 Recommandations

En ce qui concerne les prévisions de la demande, notre analyse a révélé que les méthodes les plus performantes varient en fonction des produits. Par conséquent, nous proposons d'adapter les modèles en fonction des produits. Pour l'ITEM001, nous recommanderions l'utilisation de Prophet qui a montré une amélioration de 28,2% du RMSSE comparé à la méthode actuelle. Pour l'ITEM002, nous suggérons de conserver la moyenne mobile sur 12 mois. Nous recommanderions en outre un suivi périodique des modèles (tous les 6 ou 12 mois) afin de vérifier leur performance avec les nouvelles données.

En ce qui a trait à la gestion des stocks, nous vous suggérons d'adopter graduellement une nouvelle politique et d'abandonner celle qui vise un stock de trois ventes moyennes. La nouvelle politique se baserait non seulement sur les prévisions, mais aussi sur un stock de sécurité prenant en compte les écarts de prévision (RMSE). Cette approche permettrait de réduire les coûts de possession des stocks et le capital investi, grâce à une diminution du niveau moyen des stocks, tout en assurant un niveau de service élevé. De plus, afin de réduire encore davantage les stocks moyens, nous proposons d'ajuster le facteur de service (z) pour trouver un meilleur arbitrage entre le risque de rupture et le coût du stockage.

En ce qui concerne la gestion des données, nous proposons de continuer à collecter des données historiques pour améliorer la qualité des prévisions et surveiller les indicateurs de performance des modèles (RMSSE, wMAPE, RMSE). En définitive, nous suggérons d'étendre la démarche d'évaluation des modèles de prévisions pour les autres articles. Ce procédé permettrait de déterminer les modèles de prévision les plus fiables pour chaque produit et d'optimiser leur gestion des stocks.

4. Conclusion

Dans le cadre de ce projet, nous avons pour objectif d'améliorer la prévision de la demande et de proposer une politique de stock plus efficace. Nous avons constaté que Prophet est meilleur pour l'ITEM001, alors que la méthode actuelle est préférable pour l'ITEM002. En outre, l'application de notre nouvelle politique de stockage entraînerait une diminution importante des stocks cibles et du niveau moyen des stocks par rapport à la politique actuelle. Cela reviendrait pour l'entreprise à réduire ses coûts de stockage, tout en maintenant un niveau de service élevé.

4.1 Limites : à revoir, juste des idées

Néanmoins, notre projet présente des limites qui atténuent son impact, sa rigueur et sa profondeur d'analyse. Premièrement, les données sont assez restreintes, puisque nous ne disposons que de 53 mois de données historiques, ce qui limite l'utilisation de modèles statistiques plus complexes. De plus, les données de test ne sont pas plus abondantes, avec seulement cinq mois à disposition. Enfin, plusieurs mois ont une demande nulle, ce qui rend l'évaluation et la validation des modèles plus difficiles.

Au niveau méthodologique, le RMSSE a été calculé à l'aide d'un modèle naïf basé sur le mois précédent ($t-1$) plutôt que sur le mois correspondant de l'année précédente. Bien qu'une tendance soit observable, il aurait été judicieux de comparer les performances du modèle avec un modèle naïf saisonnier utilisant le même mois de l'année précédente. En effet, les résultats peuvent varier considérablement en fonction du choix de l'indicateur d'erreur. En définitive, seuls deux articles ont été analysés, ce qui limite la possibilité de tirer des conclusions globales sans une étude plus exhaustive.

En ce qui concerne l'analyse des ventes, nous ne prenons en compte que les données historiques. Or, de nombreux autres facteurs peuvent influencer la demande, tels que l'entrée ou la sortie de concurrents, l'évolution de leurs prix (par exemple, des promotions), le climat économique de l'entreprise ou l'arrivée de nouveaux clients importants. Plusieurs facteurs peuvent déclencher des fluctuations soudaines de la demande, ces changements étant impossibles à anticiper à partir des seules données historiques de vente.

Pour la politique de stockage, le RMSE est constant sur toute la période de prévision, mais l'incertitude tend généralement à augmenter avec l'éloignement de la prévision, et il est difficile de l'évaluer. Cela affecte donc la fiabilité des résultats et de notre analyse sur la gestion des stocks. En outre, l'hypothèse de normalité des erreurs utilisée dans le calcul du stock de sécurité n'a pas pu être validée, comme nous l'avons vu dans notre analyse des stocks cibles.

4.2 Voies d'amélioration du projet

Plusieurs aspects pourraient être améliorés afin d'accroître la rigueur du projet et la pertinence des résultats et recommandations. Tout d'abord, il serait bénéfique d'enrichir les données en y incluant des données historiques plus nombreuses, d'étendre l'analyse à une variété de produits en stock et de s'appuyer sur des données externes pertinentes pour éclairer les fluctuations de la demande.

Ensuite, on pourrait améliorer les prévisions en testant des modèles plus spécialisés à une demande intermittente et en utilisant une validation croisée temporelle pour valider leur performance. De plus,

l'utilisation de différentes définitions du modèle naïf employé dans le RMSSE permettrait de renforcer la solidité des évaluations de nos modèles. En définitive, tester des ensembles de modèles (hybrides) pourrait s'avérer bénéfique en vue d'améliorer nos prévisions grâce à la création d'un modèle combinant les points forts de plusieurs autres.

Finalement, il serait possible d'optimiser davantage notre gestion des stocks en utilisant un stock de sécurité dynamique prenant en compte les fluctuations de l'incertitude en fonction de l'horizon de prévision. De plus, on pourrait évaluer différents niveaux de service théoriques pour mesurer leur impact sur les niveaux de stocks et sur le niveau de service effectivement obtenu. Enfin, réaliser ces simulations sur des périodes plus longues permettrait de mieux déterminer les impacts sur les stocks et les risques de surstockage ou de rupture de stock.

5. Contribution des membres de l'équipe

Hannaé : rédaction intégrale des parties 2 « Méthode » et 6 « Déclaration sur l'utilisation de l'IAG » du rapport. Élaboration du notebook sur Python. Slides 3 à 6 de la présentation.

Lise : rédaction des parties 3.3 « analyses prescriptives : stocks cibles », 3.4 « recommandations », et 4 « conclusions » avec limites et voies d'amélioration. Slides 9 à 12 de la présentation.

Émile : contact avec la compagnie, collecte des données, rédaction de la partie 1 "Introduction", de la partie 3.1 "Meilleur modèle" et de la partie 3.2 "Analyse prédictive : les prévisions du modèle". Slides 2, 7 et 8 de la présentation.

6. Déclaration sur l'utilisation de l'IA générative

L'outil d'intelligence artificielle (IA) Claude a été utilisé dans ce projet afin d'aider à l'élaboration du notebook Python, sur les éléments suivants :

- Traitement des données du fichier CSV : nettoyage des données en s'assurant qu'il n'y ait pas d'erreurs pour la définition des fonctions en aval.
- Conception visuelle des graphiques : précisément pour les aspects esthétiques comme la mise en forme, les couleurs, courbe de tendance, etc.

Cependant, la structure du code, les décisions de la logique, et les décisions conceptuelles pour répondre aux objectifs de notre projet ont été élaborées sans usage de l'IA.

7. Bibliographie

Cousineau, Martin (2026-a). OPER60500 Analytique de la chaîne logistique, notes du cours 3 [présentation PowerPoint], HEC Montréal.

Cousineau, Martin (2026-b). OPER60500 Analytique de la chaîne logistique, notes du cours 4 [présentation PowerPoint], HEC Montréal.

Cousineau, Martin (2026-c). OPER60500 Analytique de la chaîne logistique, notes du cours 5 [présentation PowerPoint], HEC Montréal.

Cousineau, Martin (2026-d). OPER60500 Analytique de la chaîne logistique, notes du cours 7 [présentation PowerPoint], HEC Montréal.

Google Colab. (n.d.-a).

https://colab.research.google.com/github/acedesci/scanalytics/blob/master/FR/S07_Time_Series/S07_Demo2_Time_Series_fr.ipynb

Google Colab. (n.d.-b).

https://colab.research.google.com/github/acedesci/scanalytics/blob/master/FR/S07_Time_Series/S07_Demo4_Dynamic_inventory_fr.ipynb

Google Colab. (n.d.-c).

https://colab.research.google.com/github/acedesci/scanalytics/blob/master/FR/S05_Descriptive_Analytics/S05_Lecture_Examples1_Solution_fr.ipynb